Predicción del éxito académico en educación superior

1. Introducción

Este proyecto aborda tres tareas complementarias sobre el mismo conjunto de datos: clasificación de la situación final del estudiante (*abandono*, *graduado* o *matriculado*), regresión de la `nota_media_2sem` y análisis no supervisado para detectar perfiles latentes. El objetivo no es únicamente obtener buenas métricas, sino evaluar hasta qué punto la información disponible antes o durante el primer semestre permite anticipar trayectorias académicas útiles para la toma de decisiones.

La principal restricción metodológica del trabajo ha sido evitar fuga de información. Por ello, en clasificación y regresión se excluyeron sistemáticamente las variables del segundo semestre, ya que contienen información contemporánea o casi equivalente al resultado que se intenta predecir. Esta decisión reduce la potencia predictiva inmediata, pero hace que los resultados sean mucho más creíbles desde el punto de vista aplicado: el interés del problema no es reconstruir el presente, sino anticipar situaciones de riesgo con margen de intervención.

2. Exploración inicial y decisiones de preprocesado

El conjunto contiene 4424 observaciones y 37 variables, con 18 variables categóricas y 19 numéricas. No aparecen valores nulos ni duplicados, lo que simplifica el preprocesado y permite centrar el análisis en la estructura del problema en lugar de en tareas intensivas de limpieza. La variable objetivo presenta, sin embargo, un desbalance moderado: *graduado* representa aproximadamente el 49,9 % de la muestra, *abandono* el 32,1 % y *matriculado* solo el 17,9 %. Esta asimetría condiciona directamente la elección de métricas y explica por qué la accuracy por sí sola sería engañosa.

El análisis exploratorio muestra dos hechos relevantes. Primero, las variables ligadas al rendimiento del primer semestre ya contienen mucha señal sobre la trayectoria posterior: asignaturas aprobadas, evaluadas y nota media separan de forma visible a los grupos. Segundo, algunas variables administrativas y socioeconómicas (`matricula_al_dia`, `deudor`, `becado`) también muestran diferencias, aunque menores. Esto sugiere que el rendimiento académico temprano es el núcleo del problema, mientras que las variables de contexto actúan como moduladores del riesgo más que como determinantes principales. Esta observación se ve reforzada por la matriz de correlaciones: las variables del primer semestre forman un bloque altamente correlacionado entre sí (especialmente `asignaturas_1sem_aprobadas`, `asignaturas_1sem_evaluadas` y `nota_media_1sem`), lo que anticipa que la señal está concentrada en pocas dimensiones reales y que los modelos con selección implícita de variables como Lasso o Random Forest podrían aprovechar esta estructura mejor que los modelos lineales sin regularización.

Se detectaron valores extremos en varias variables mediante z-score, pero no se eliminaron. Esta decisión es razonable porque muchos de esos extremos no parecen errores de medida, sino perfiles reales del alumnado: estudiantes de mayor edad, convalidaciones o trayectorias académicas atípicas. Eliminar esos casos habría "limpiado" artificialmente un fenómeno que precisamente interesa entender. Sí se realizó limpieza de espacios en variables categóricas y codificación *one-hot*, lo que elevó el número de predictores hasta 232 columnas.

La alta dimensionalidad resultante tras la codificación anticipaba dos riesgos concretos: inestabilidad numérica en modelos lineales sin regularización, por la aparición de multicolinealidad severa entre las columnas dummy, y necesidad de controlar la complejidad en modelos flexibles para evitar sobreajuste. Ambos riesgos se

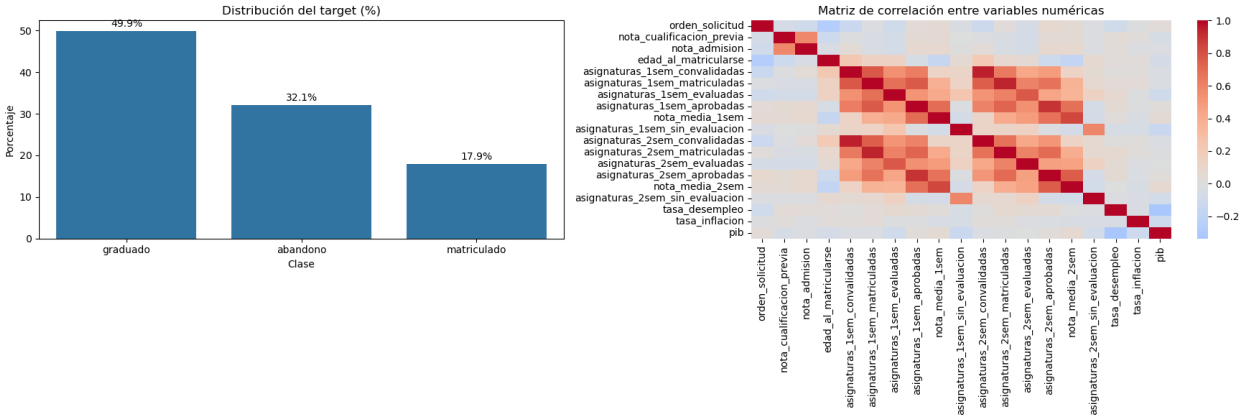


Figura 1: Mapa de correlaciones entre variables numéricas y distribución de la variable objetivo

materializaron en los análisis posteriores y condicionaron las decisiones de modelización.

3. Clasificación multiclase

3.1. Planteamiento y criterio de evaluación

La tarea de clasificación se formuló con un *train/test split* de 80/20 y validación cruzada estratificada de 5 pliegues. Se compararon tres familias de modelos: regresión logística, árbol de decisión y random forest. La métrica principal fue el *F1 macro*, porque pondera por igual las tres clases y penaliza especialmente el mal rendimiento en la clase minoritaria *matriculado*. Esta elección es coherente con el objetivo del proyecto: un modelo que clasifique bien a los casos mayoritarios pero ignore a los estudiantes más difíciles de identificar sería poco útil para intervención educativa.

3.2. Resultados base

Como referencia mínima se entrenó también un clasificador dummy (estrategia de clase mayoritaria), que obtiene accuracy = 0.499 y F1 macro = 0.222. Todos los modelos comparados superan ampliamente este umbral, lo que confirma que existe señal predictiva real en las variables disponibles.

Los modelos base ofrecen una primera lectura interesante. La regresión logística obtuvo **accuracy = 0.736** y **F1 macro = 0.650**; el árbol de decisión, **0.725** y **0.609**; y el random forest, **0.738** y **0.624**. La conclusión no es simplemente que "logística y random forest funcionan parecido", sino que capturan ventajas distintas. La regresión logística es más equilibrada en media, mientras que el random forest logra una accuracy ligeramente superior empujado por su buen comportamiento en *graduado*. En cambio, el árbol confirma una intuición clásica: un único árbol resulta interpretable, pero demasiado inestable y con menor capacidad de generalización.

El punto débil común es la clase matriculado, cuyo recall en los modelos base se sitúa entre 0,19 y 0,31, muy por debajo del resto. Esto sugiere que no es un grupo homogéneo, sino una situación intermedia que mezcla perfiles cercanos tanto a abandono como a graduación. Desde un punto de vista del problema, tiene sentido, seguir matriculado no implica ni fracaso ni éxito, sino un estado en el que la trayectoria futura es más incierta. La mayoría de los errores se dirigen hacia graduado y no hacia abandono, lo que refuerza la idea de que estos estudiantes comparten más características con quienes terminan graduándose que con quienes abandonan.

3.3. Validación cruzada y optimización

La validación cruzada confirmó que la regresión logística era el modelo base más estable (*F1 macro* medio $= 0{,}656 \pm 0{,}007$), mientras que el árbol tenía mayor varianza ($0{,}594 \pm 0{,}037$). Sin embargo, tras el ajuste de hiperparámetros apareció un resultado importante: el **random forest optimizado** pasó a ser el mejor modelo final con **accuracy = 0.730** y **F1 macro = 0.680**. La accuracy incluso baja ligeramente respecto al random forest base, pero el F1 macro sube de manera clara. Esta aparente contradicción muestra que el modelo sacrifica algo de rendimiento en clases fáciles para mejorar el equilibrio global, especialmente en la clase minoritaria.

En la regresión logística optimizada, el parámetro más relevante fue la introducción de `class_weight='balanced'`, que repondera las muestras inversamente proporcional a la frecuencia de cada clase. Esto explica la caída de *accuracy* de 0.736 a 0.697: el modelo penaliza más los errores en *matriculado* y *abandono*, sacrificando deliberadamente precisión en *graduado*.

En el random forest, los parámetros óptimos fueron `n_estimators=200`, `max_depth=10` y `max_features='sqrt'`, configuración que aumenta la diversidad entre árboles y controla el sobreajuste sin penalizar el rendimiento en las clases mayoritarias.

Ese efecto se observa en detalle al comparar por clase. El random forest optimizado mantiene un rendimiento alto en *abandono* y *graduado*, pero mejora *matriculado* hasta un **recall = 0.53** y **F1 = 0.48**. La regresión logística optimizada consigue un recall similar en *matriculado* (0,51), aunque a costa de una caída mayor de accuracy global. El árbol optimizado extrema todavía más este patrón: sube mucho el recall de *matriculado* (0,66), pero empeora tanto en las otras clases que el resultado agregado ya no compensa. Esto refleja un compromiso inevitable entre el rendimiento en la clase minoritaria y la estabilidad global del modelo.

Modelo	Accuracy test	F1 macro test
Regresión logística	0.736	0.650
Árbol de decisión	0.725	0.609
Random forest	0.738	0.624
Regresión logística optimizada	0.697	0.650
Árbol optimizado	0.623	0.599
Random forest optimizado	**0.730**	**0.680**

Cuadro 1: Comparación de resultados en clasificación.

Se analizó además el efecto del desbalanceo de clases comparando Random Forest con y sin `class_weight='balanced'` sobre el conjunto de test. El resultado es contraintuitivo: el modelo sin balanceo obtiene mejor $F1_{macro}$ (0.624 vs. 0.592) y, paradójicamente, mayor *recall* en *matriculado* (0.21 vs. 0.16).

Esto sugiere que la reponderación de clases en un modelo base de 100 árboles no es suficiente para compensar la dificultad intrínseca de la clase minoritaria, y que la mejora observada en el modelo optimizado final proviene principalmente del ajuste conjunto de hiperparámetros (profundidad, número de árboles y balanceo), no del balanceo en aislamiento.

3.4. Interpretación

Las importancias del random forest refuerzan la lectura del EDA. Las variables dominantes son `asignaturas_1sem_aprobadas`, `nota_media_1sem`, `matricula_al_dia_si` y `asignaturas_1sem_evaluadas`. La conclusión relevante no es solo que el rendimiento previo importa, sino que el modelo combina dos dimensiones: desempeño académico y regularidad administrativa. Aprobar y obtener buenas notas parece separar principalmente a graduados de abandonos, mientras que estar al día con la matrícula introduce una señal adicional de compromiso o estabilidad institucional.

Aun así, que algo aparezca como importante no quiere decir que realmente esté causando el resultado. Por ejemplo, `matricula_al_dia` puede reflejar factores como capacidad económica, organización personal o

ausencia de incidencias, pero no ser la causa directa. Además, las importancias de un random forest no miden el efecto aislado de cada variable, sino cuánto ayudan a predecir dentro de la estructura del modelo. Por eso, son útiles para orientar qué variables parecen relevantes, pero no para sacar conclusiones directas sobre qué factores están causando el resultado. La matriz de confusión confirma este comportamiento. El modelo mantiene un rendimiento alto en las clases abandono y graduado, especialmente en esta última, donde la mayoría de los casos se clasifican correctamente. En el caso de matriculado, aunque el recall mejora respecto a otros modelos, sigue siendo la clase con mayor nivel de confusión, especialmente hacia graduado. Esto sugiere que el modelo logra un mejor equilibrio global, pero que la separación entre ciertas clases sigue siendo limitada.

La matriz de confusión revela además una asimetría relevante: abandono se confunde principalmente con graduado (33 casos) y con matriculado (56 casos), mientras que graduado apenas se confunde con abandono (21 casos). Esto sugiere que el modelo tiene más dificultad para identificar el riesgo de abandono en estudiantes con perfil intermedio que para confirmar el éxito en estudiantes claramente orientados a la graduación. Desde una perspectiva de intervención educativa, este sesgo es el más costoso: los falsos negativos de abandono son exactamente los estudiantes que más necesitarían atención temprana.

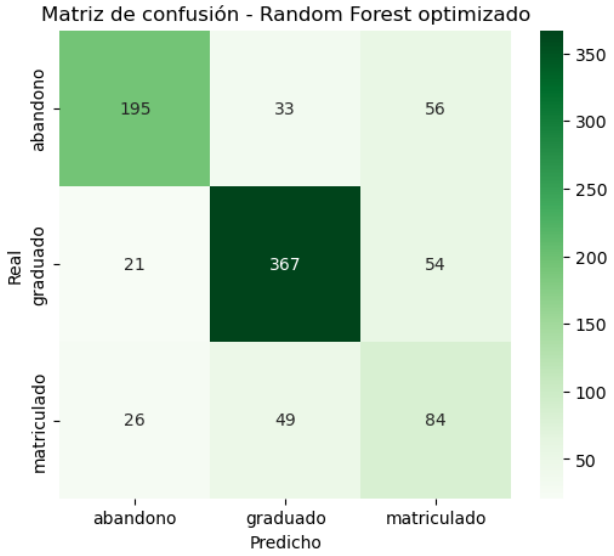


Figura 2: Matriz de confusión de Random Forest optimizado

Para validar la robustez de las importancias internas del Random Forest, se calculó la *permutation importance* sobre el conjunto de test, midiendo la caída real en $F1_{macro}$ al permutar aleatoriamente cada variable. Los resultados son consistentes con los anteriores: `asignaturas_1sem_aprobadas` es, con diferencia, la variable más relevante (caída de 0.089), seguida de `matricula_al_dia_si` (0.045) y `nota_media_1sem` (0.041).

Esta concordancia entre dos métodos de importancia independientes —uno basado en la impureza durante el entrenamiento y otro en la degradación del rendimiento en test— refuerza la confianza en el resultado y descarta que el ranking observado sea un artefacto del algoritmo concreto.

4. Regresión del rendimiento en segundo semestre

4.1. Planteamiento

La regresión intenta predecir `nota_media_2sem` usando solo información previa: variables de entrada, contexto y rendimiento del primer semestre. Esta tarea es conceptualmente muy exigente, porque se busca anticipar una variable continua fuertemente ligada a procesos académicos todavía no observados. Se compararon *Dummy*

Regressor, regresión lineal, Ridge, Lasso, árbol de regresión y random forest, siempre validando y ajustando hiperparámetros exclusivamente sobre entrenamiento.

Como en clasificación, se excluyeron sistemáticamente las variables del segundo semestre para evitar fuga de información. En concreto, se eliminaron `asignaturas_2sem_matriculadas`, `asignaturas_2sem_evaluadas`, `asignaturas_2sem_aprobadas`, `asignaturas_2sem_convalidadas` y `asignaturas_2sem_sin_evaluacion`, dado que son contemporáneas a la variable objetivo o prácticamente equivalentes a ella.

4.2. Resultados y lectura crítica

Al igual que en clasificación, se utilizó un `Dummy Regressor` como referencia mínima, en este caso prediciendo siempre la media del conjunto de entrenamiento, obteniendo RMSE = 5,203 y $R^2 \approx 0$. Todos los modelos regularizados y basados en árboles lo superan, lo que confirma que existe señal predictiva real en las variables previas al segundo semestre.

El primer resultado relevante es el colapso de la regresión lineal ordinaria: **RMSE** $\approx 1{,}1 \times 10^{13}$ y un R^2 extremadamente negativo. Este comportamiento no es anecdótico, sino metodológicamente informativo. Tras la codificación *one-hot*, el diseño queda muy cercano a multicolinealidad severa, al invertir implícitamente una matriz mal condicionada, la estimación se vuelve numéricamente inestable. Por tanto, el fracaso de la lineal no implica que la relación subyacente sea no lineal, sino que el problema exige regularización.

Ridge corrige de forma drástica esta inestabilidad (**RMSE = 2.674**, **MAE = 1.606**, $R^2 = 0{,}736$) y Lasso mejora todavía algo más en test (**RMSE = 2.637**, **MAE = 1.506**, $R^2 = 0{,}743$). Este resultado es importante porque muestra que una parte muy sustancial del rendimiento en segundo semestre sí puede anticiparse con información previa, pero solo si se controla la complejidad del modelo. Además, Lasso introduce simplicidad en el modelo y permite interpretar mejor qué variables están influyendo.

Los hiperparámetros óptimos se obtuvieron mediante `GridSearchCV` exclusivamente sobre el conjunto de entrenamiento. Para Ridge, el valor óptimo fue $\alpha = 100$, una penalización relativamente fuerte que refleja la alta dimensionalidad del espacio de predictores. Para Lasso, $\alpha = 0{,}05$, un valor más suave que mantiene activos la mayoría de coeficientes pero anula los menos informativos, realizando así una selección implícita de variables.

El árbol óptimo empleó `max_depth=5` y `min_samples_leaf=10`, restricciones que evitan el sobreajuste sin sacrificar capacidad expresiva.

Random forest ofrece un matiz clave: no es el mejor en R^2 ni en RMSE, pero sí en **MAE = 1.393** y en validación cruzada fue el modelo más fuerte (**CV RMSE medio = 2.478**). Esto sugiere que comete errores grandes con menor frecuencia y se adapta mejor a relaciones no lineales, aunque no necesariamente optimiza la variabilidad global de la respuesta mejor que Lasso. En términos prácticos, si el interés fuese minimizar el error típico de predicción estudiante a estudiante, random forest sería muy competitivo. Pero si el objetivo es tener una explicación más simple y consistente del rendimiento, Lasso resulta más razonable.

Modelo	RMSE test	MAE test	R^2 test
Dummy	5.203	4.022	0.000
Lineal	$1{,}1 \cdot 10^{13}$	$5{,}3 \cdot 10^{11}$	< 0
Ridge	2.674	1.606	0.736
Lasso	**2.637**	1.506	**0.743**
Árbol	2.775	1.439	0.716
Random forest	2.667	**1.393**	0.737

Cuadro 2: Comparación de modelos de regresión en test.

4.3. Interpretación de variables

Tanto Lasso como random forest coinciden en dos predictores dominantes: `nota_media_1sem` y `asignaturas_1sem_aprobadas`. Esta coincidencia entre un modelo lineal regularizado y uno no lineal es especialmente valiosa, porque refuerza la confianza en el resultado y sugiere que no depende del modelo utilizado. No parece ser algo específico de un algoritmo concreto, sino que el rendimiento del estudiante en el primer semestre resume bastante bien su potencial de rendimiento posterior.

Cuantitativamente, el coeficiente de Lasso para `nota_media_1sem` es de 2,81 y el de `asignaturas_1sem_aprobadas` de 2,08, siendo los únicos con una magnitud claramente superior al resto. Esto indica que una unidad de mejora en la nota media del primer semestre se traduce, en media, en casi tres puntos adicionales en la nota del segundo, manteniendo constante el resto de variables. La escala de este efecto refuerza que el rendimiento temprano no es solo estadísticamente significativo, sino también relevante en términos prácticos.

A partir de ahí se empiezan a ver algunas diferencias interesantes. Lasso da cierto peso a variables más administrativas como `matricula_al_dia_si` y a algunas dummies de curso, lo que sugiere que, incluso controlando el nivel académico previo, siguen existiendo diferencias entre perfiles o titulaciones. En random forest estas variables también aparecen, pero con bastante menos peso, lo que indica que su influencia es real, pero claramente secundaria frente al rendimiento académico.

El análisis de residuos indica un ajuste globalmente razonable, aunque lejos de ser perfecto. La nube principal se concentra en torno a cero, lo que sugiere que el modelo no presenta un sesgo sistemático claro, pero aparecen patrones que no son aleatorios. En ambos modelos se observan estructuras definidas en los residuos, especialmente bandas diagonales, lo que apunta a limitaciones en la capacidad del modelo para capturar ciertas relaciones del problema.

En el caso de Lasso, los residuos muestran mayor dispersión en algunos rangos, lo que sugiere que el modelo lineal no logra adaptarse bien a determinadas zonas del espacio de predicción. Por su parte, Random Forest presenta una nube más compacta alrededor de cero, indicando un mejor ajuste local, aunque persisten errores sistemáticos en ciertos tramos, lo que sugiere que incluso el modelo no lineal no capta completamente la complejidad del fenómeno.

En conjunto, estos patrones reflejan que parte del error no es simplemente ruido, sino que responde a información no capturada por las variables disponibles. Esto es coherente con la naturaleza del problema: incluso con buen rendimiento predictivo, la nota del segundo semestre depende de factores no observados en el dataset, como cambios de motivación, dificultad específica de asignaturas o circunstancias personales.

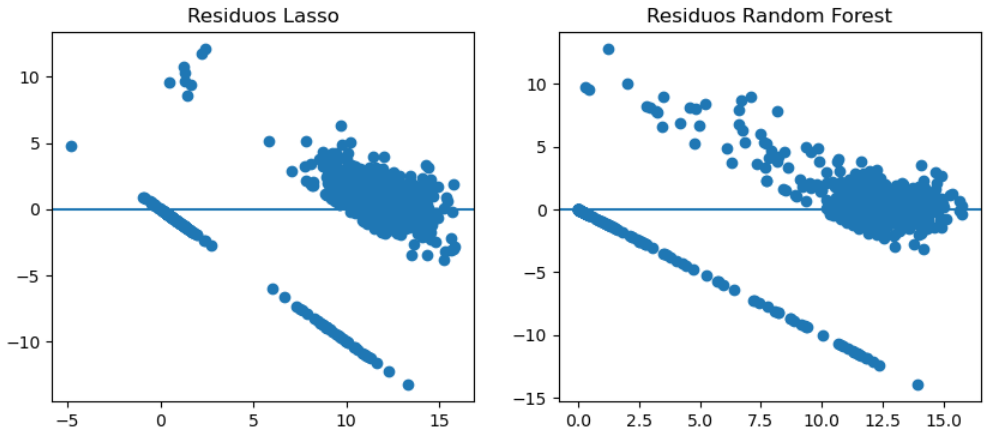


Figura 3: Comparación de residuos

Las bandas diagonales visibles en ambos gráficos de residuos merecen una mención específica: son coherentes con la naturaleza discreta o semi-discreta de la variable objetivo, ya que las notas tienden a concentrarse en valores enteros o medios enteros. Esto genera agrupaciones estructurales en los residuos que ningún modelo

continuo puede eliminar completamente, y explica por qué los patrones persisten incluso en Random Forest.

5. Análisis no supervisado

El análisis no supervisado se construyó sobre las mismas variables pre-segundo semestre, excluyendo también la variable objetivo. Tras codificación y escalado, el PCA mostró una primera advertencia metodológica: las dos primeras componentes solo explican el **4 %** de la varianza total, y hacen falta 132 componentes para llegar al 80 %. Por tanto, la proyección en dos dimensiones es útil para visualizar, pero claramente insuficiente para representar fielmente toda la estructura del problema. Esta dispersión de la varianza es coherente con la naturaleza del dataset: tras la codificación one-hot, las 232 columnas recogen información heterogénea, rendimiento académico, variables socioeconómicas, dummies de curso y nacionalidad, que no se reduce fácilmente a unos pocos ejes. No es un síntoma de que los datos carezcan de estructura, sino de que esa estructura es multidimensional y no lineal.

Para clustering se evaluó KMeans con $k = 2, \ldots, 10$ usando inercia y *silhouette*. Los valores de *silhouette* son bajos en todos los casos, con máximo en $k = 2$ (0,113) y un valor muy cercano en $k = 3$ (0,107). Elegir $k = 3$ es sensato no porque los clusters estén muy bien separados, sino porque aporta un compromiso razonable entre calidad geométrica y la capacidad interpretativa. Esto es importante: el clustering no está detectando grupos claramente aislados, sino organizando perfiles que en realidad forman parte de una población continua. Para completar el análisis de estabilidad, se evaluó también la inercia, que decrece de forma gradual sin mostrar un codo pronunciado, lo que refuerza la conclusión de que no existe un número de clusters "natural" en estos datos. La elección de k = 3 se justifica por tanto desde la interpretabilidad y la coherencia con las tres clases del problema supervisado, no por criterios puramente geométricos.

Los tres clusters obtenidos son además muy desiguales en tamaño (3058, 376 y 990 estudiantes), lo que ya sugiere que no representan segmentos equivalentes. El perfilado posterior aclara su sentido. El **cluster 1** reúne estudiantes con mejor nota de admisión y mejor rendimiento en primer semestre; el **cluster 0** concentra un perfil intermedio y mayoritario; y el **cluster 2** agrupa estudiantes de mayor edad media y peor desempeño inicial. La relación con la variable objetivo, aunque no se usó para construir los clusters, valida parcialmente este resultado ya que en el cluster 2 el abandono alcanza **56.4 %**, mientras que en el cluster 0 predominan los graduados (**56.2 %**). El cluster 1, el de mejor rendimiento, presenta una tasa de abandono de solo el (**25 %**) y de graduación del (**47 %**), mientras que el cluster 0 intermedio muestra un perfil más equilibrado con (**28 %**) de abandono y (**47 %**) de graduados. Esta gradación confirma que los clusters capturan un eje de riesgo real, aunque con solapamiento considerable entre grupos adyacentes.

Este resultado es conceptualmente interesante porque muestra que el aprendizaje no supervisado recupera parcialmente la estructura del problema supervisado sin necesidad de etiquetas. No obstante, también deja ver sus límites: el cluster "de riesgo" no equivale exactamente a la clase abandono, y los perfiles intermedios siguen solapándose. La utilidad del clustering está, por tanto, más en segmentar población para diagnóstico institucional que en sustituir a un clasificador. Desde el punto de vista metodológico, el análisis no supervisado complementa a los modelos supervisados de una forma que estos no pueden ofrecer por sí solos: permite segmentar la población sin depender de etiquetas, lo que lo hace aplicable en contextos donde la variable objetivo no está disponible aún, por ejemplo, al inicio del primer semestre, antes de conocer ningún resultado académico.

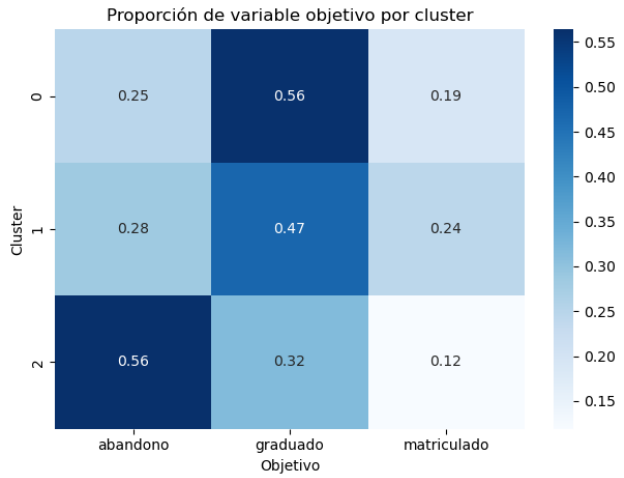


Figura 4: Distribución de la variable objetivo por cluster

6. Conclusiones y limitaciones

Los resultados permiten extraer cinco conclusiones principales. Primero, la variable más informativa en todas las tareas es el rendimiento del primer semestre: aprobar más asignaturas y obtener mejores notas no solo se asocia con graduación, sino también con mejor nota futura. Segundo, las variables administrativas y socioeconómicas añaden información útil, pero su papel es secundario respecto a la señal académica. Tercero, el problema exige metodología cuidadosa: excluir variables del segundo semestre y regularizar modelos lineales no reduce calidad, sino que evita conclusiones artificialmente optimistas. Cuarto, la clase *matriculado* es el principal reto en clasificación porque representa un estado intermedio y heterogéneo. Quinto, los tres análisis convergen en el mismo resultado desde ángulos distintos: las variables del primer semestre dominan en importancia del random forest de clasificación, en los coeficientes Lasso de regresión, y como eje discriminativo principal en el clustering. Esta coherencia entre marcos analíticos independientes refuerza la robustez de la conclusión y sugiere que no es un artefacto de ningún modelo concreto.

Desde una perspectiva aplicada, el proyecto sugiere que una institución educativa podría usar señales tempranas del primer semestre para priorizar seguimiento académico, especialmente en estudiantes con bajo número de aprobadas, peor nota media y mayor irregularidad administrativa. Sin embargo, estas conclusiones deben entenderse como predictivas y no causales. El hecho de que una variable ayude a predecir no implica que intervenir directamente sobre ella produzca el efecto esperado.

El cluster de riesgo identificado en el análisis no supervisado, estudiantes de mayor edad y peor desempeño inicial, representa precisamente este perfil, y su detección no requiere esperar al final del primer semestre: muchas de sus características son observables en el momento de la matrícula.

Entre las limitaciones del estudio destacan cuatro. En primer lugar, la representación *one-hot* aumenta mucho la dimensionalidad y dificulta algunos modelos. En segundo lugar, varias variables contextuales pueden estar actuando como indicadores indirectos difíciles de interpretar causalmente. En tercer lugar, el análisis no supervisado revela más continuidad que separación nítida entre perfiles. Por ello, el valor del trabajo no reside en haber encontrado fronteras perfectas, sino en haber construido una metodología coherente y en extraer conclusiones honestas sobre qué puede anticiparse y qué no con la información disponible. En cuarto lugar, el dataset recoge un único contexto institucional, lo que limita la generalización de los resultados a otros entornos educativos con distribuciones demográficas o sistemas de evaluación distintos.

Referencias

[1] Scikit-learn developers. (n.d.). *Pipeline*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html

[2] Scikit-learn developers. (n.d.). *GridSearchCV*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

[3] Scikit-learn developers. (n.d.). *StandardScaler*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html

[4] Scikit-learn developers. (n.d.). *DummyClassifier*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.dummy.DummyClassifier.html

[5] Scikit-learn developers. (n.d.). *DummyRegressor*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.dummy.DummyRegressor.html

[6] Scikit-learn developers. (n.d.). *KMeans*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html

[7] Scikit-learn developers. (n.d.). *PCA*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html

[8] Scikit-learn developers. (n.d.). *StratifiedKFold*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedKFold.html

[9] Scikit-learn developers. (n.d.). *cross_val_score*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.cross_val_score.html